

队伍编号	MC2603771
题号	C

基于集成学习与多目标优化的 中老年高血脂症精准防控方法研究

摘要

针对中老年人群高血脂症防控过程中“体质难以量化刻画、风险分层精度不足以及干预策略缺乏个性化”的关键问题，本文在中医体质理论与西医生化指标融合框架下，构建了一套多维度统计建模与优化决策体系，实现高血脂风险的精准预警与干预方案的最优设计。

在特征筛选阶段，我们构建 LASSO 回归与随机森林双模型，通过融合回归系数与特征重要性，筛选出总胆固醇（TC）、甘油三酯（TG）、低密度脂蛋白（LDL-C）、高密度脂蛋白（HDL-C）及空腹血糖等核心指标，实现对痰湿体质表征能力与高血脂风险预警能力的统一刻画。在此基础上，进一步建立多元 Logistic 回归模型，对九种中医体质的风险贡献进行量化分析。结果表明，各体质对高血脂的影响主要通过代谢指标产生间接作用，其独立解释能力有限。

在风险预警方面，我们融合体质特征、血常规指标、活动能力及人口学信息，构建逻辑回归概率预测模型，并基于 ROC 曲线与分位数方法确定低—中—高三级风险分层阈值（AUC=0.9719）。进一步利用 CART 决策树提取可解释判别规则，识别出 TG、TC 及血尿酸为核心分层指标。同时，基于 Apriori 算法挖掘高风险人群的特征组合，发现“饮酒+高 TG”“老年+高 TC”等典型高危模式。

在干预优化阶段，我们针对痰湿体质人群构建多目标约束优化模型，以最小化痰湿积分与干预成本为优化目标，在年龄与活动能力约束下，通过穷举法求解个体最优干预方案。结果表明，该模型可实现最高 56.6% 的痰湿积分下降，并总结出“强度优先、频率适配”的最优干预策略。

研究结果表明：血脂与血糖指标构成连接中医体质与高血脂风险的关键桥梁，多维融合建模方法能够显著提升风险预警精度，并为中西医结合慢性病管理提供可解释且可实施的量化决策工具。

关键词：高血脂症；LASSO 回归；随机森林；Logistic 回归

目录

摘 要	1
一、问题背景	1
二、研究问题	2
三、理论与模型假设	3
四、问题一模型的建立和求解	5
4.1 样本数据预处理与标准化	5
4.1.1 数据质量检验与可靠性分析	5
4.1.2 极值化 (Min-Max) 归一化与正向化处理	5
4.1.3 变量处理规则	5
4.1.4 选择 Min-Max 归一化的合理性分析	6
4.2 问题一第一小问的模型建立	7
4.2.1 痰湿体质严重程度: LASSO 回归模型	7
4.2.2 高血脂发病风险: 随机森林分类模型	7
4.2.3 综合筛选规则	7
4.3 理论分析	8
4.4 实验结果与分析	8
4.4.1 LASSO 回归结果	8
4.4.2 随机森林分类结果	10
4.4.3 综合筛选结果	11
4.5 问题一第二小问的模型建立	12
4.6 理论分析	13
4.7 实验结果与分析	13
4.7.1 多重共线性检验 (VIF)	13
4.7.2 模型整体效果评价	14
4.7.3 九种体质贡献度排序与结果分析	14
五、问题二模型的建立和求解	16
5.1 子问题一: 多维度融合风险预警模型构建	16
5.1.1 模型构建思路	16
5.1.2 逻辑回归概率预测模型	16
5.1.3 三级风险阈值确定	19
5.1.4 决策树提取特征分层阈值规则	20
5.1.5 关键特征在各风险等级均值对比	22
5.1.6 ROC 曲线与最优阈值	23
5.1.7 子问题一结论	24
5.2 子问题二: 痰湿体质高风险人群核心特征组合识别	24
5.2.1 研究思路	24
5.2.2 目标群体筛选	25
5.2.3 特征离散化处理	25
5.2.4 特征组间差异与卡方检验	26
5.2.5 特征共现热力图分析	27
5.2.6 Apriori 频繁项集挖掘	28
5.2.7 关联规则分布与核心组合识别	30

5.2.8 核心特征组合中西医机制解释	32
5.2.9 子任务二结论	33
六、问题三模型的建立和求解	34
6.1 模型假设	错误！未定义书签。
6.2 模型构建	34
6.2.1 中医调理分级规则	34
6.2.2 月度积分下降率模型	34
6.2.3 痰湿积分递推公式	34
6.2.4 成本模型	35
6.2.5 约束条件	35
6.2.6 目标函数	36
6.3 模型求解方法	36
6.4 典型样本最优干预方案（ID=1、2、3）	36
6.4.1 样本 ID=1	36
6.4.2 样本 ID=2	37
6.4.3 样本 ID=3	38
6.5 患者特征 — 最优方案匹配规律	38
1, 强度策略——就高不就低	39
2.频率策略——预算允许内拉满	39
3.TCM 分级的首月效应	39
4.经济效率递减规律	39
6.6 模型结论	40
七、模型的优缺点分析	41
(1) 模型优点	41
1.多维度融合，预警精度高	41
2.可解释性强，贴合临床应用	41
3.优化模型实用，干预方案个性化	41
4.算法稳健，适配医疗数据特性	41
5.中西医结合，理论与实践统一	41
(2) 模型缺点	41
1.体质独立解释力有限	41
2.决策树特征覆盖范围窄	41
3.干预模型为静态固定方案	41
4.样本代表性存在局限	42
5.关联规则提升度偏低	42
(3) 改进方向	42
参考文献	43

一、问题背景

人口老龄化进程的持续加快，使得 40 岁及以上中老年人群成为慢性病防控的核心群体。其中，高脂血症（血脂异常）的发病率呈逐年攀升态势。根据《中国心血管健康与疾病报告 2022》，我国成人血脂异常的患病率已高达 35.6%^[1]。高脂血症已成为诱发冠心病、脑梗死等动脉粥样硬化性心脑血管疾病（ASCVD）的重要危险因素，严重威胁中老年群体的心血管健康与生活质量^[2]。

从中医体质学视角来看，体质禀赋与偏颇是疾病发生发展的内在根基。其中，痰湿体质被公认为中老年高脂血症的高发体质类型^[3]。该体质人群存在痰湿内蕴、脾胃运化失常、水湿代谢不畅的核心特征；而脾失健运、痰湿阻滞恰与西医血脂代谢异常的病理机制高度契合。痰湿膏脂内停于脉道，终致血脂紊乱，二者的病理关联为中西医结合防控高脂血症提供了重要理论支撑^[4]。同时，中老年人日常活动能力（ADL/IADL）的强弱直接影响机体气血津液的运行与脏腑功能的调和，与痰湿体质的改善及体内膏脂的代谢呈显著正相关^[5]。

然而，目前临床实践中对中老年高脂血症的防治仍面临严峻挑战。最新发布的《中国血脂管理指南（2023 年）》指出，尽管血脂管理策略在不断进步，但我国人群血脂合适水平随 ASCVD 危险分层而异，单一的生化指标监测往往难以实现对高危人群的精准预警与早期干预^[6]。

为此，通过融合中医体质特征量化指标、活动量表评分及血常规等多维数据，构建中老年高脂血症的风险预警模型，识别“痰湿体质-低活动量-血脂异常”的核心关联特征，对于推动慢病管理从“被动治疗”向“主动预防”转型，提升基层医疗服务效能具有重要的科学价值与社会意义。

二、研究问题

本次竞赛针对中老年高血脂症的防控难题，旨在融合中医体质学说与西医临床指标，通过数学建模实现精准的风险预警与个性化干预。题目通过三个核心问题，引导参赛者完成从“特征筛选”到“风险分层”再到“方案优化”的完整研究链路。

针对问题一：关键指标筛选与体质贡献度研究

该问题的核心在于从海量的体检数据和量表评分中提取最具解释性的特征。挑战在于处理血常规指标与痰湿体质程度之间的非线性关系。我们需要建立一种特征重要性评价机制（如随机森林特征选择或相关性分析），识别出既能敏锐反映痰湿内蕴程度，又能有效预警高血脂发病风险的“风向标”指标。同时，通过量化九种不同中医体质在发病样本中的分布及权重，揭示体质禀赋对疾病易感性的差异化贡献。

针对问题二：多维度融合的风险预警模型构建

此问题的重点是实现从单一指标评估向多维度综合评估的跨越。我们需要构建一个分类预测模型，输出低、中、高三级风险。难点在于确立具有医学解释力的分层阈值依据，例如如何平衡“痰湿积分”与“血脂指标”在不同风险等级中的阈值设定。此外，模型还需识别出“体质+行为+生化”的核心高危特征组合（如：痰湿体质且低活动量且血脂偏高），并结合中医病机与西医病理给出合理的因果解释。

针对问题三：基于个体特征的干预方案优化设计

该问题要求将预警转化为行动，针对确诊为“痰湿体质”的特定人群制定闭环干预策略。这是一个多目标优化问题：在确保方案符合中医调理原则（治本）与患者身体耐受度（安全）的前提下，追求痰湿积分降低的最大化以及经济成本的最小化。模型需要产出一种动态的匹配规律，能够根据患者不同的初始体征、活动能力和经济承受力，自动生成为期6个月的个性化干预路径，并对典型样本（ID 1、2、3）给出具体的最优方案建议。

三、理论与模型假设

- 1.假设附件所提供的 1000 例中老年人健康体检数据、体质积分数据、活动能力量表数据及高血脂诊断标签均真实、准确、有效，不存在严重缺失值、异常值与重复样本，且能够较为客观地反映研究对象的真实健康状态，可直接用于后续统计建模、算法训练与结果分析。
- 2.假设所有样本个体之间相互独立，不存在明显的家庭聚集性、区域聚集性或时间序列相关性；同时，Min-Max 归一化、标准化及离散化等预处理过程仅用于消除量纲差异和统一数据形式，不改变各指标之间原有的真实关联结构。
- 3.假设痰湿体质积分与血脂、血糖、活动能力等指标之间可近似满足线性回归关系，高血脂发病的对数几率与体质特征、生化指标、活动能力及人口学变量之间可近似满足线性关系，且模型残差满足基本统计要求，从而保证 LASSO 回归与 Logistic 回归模型估计结果的稳定性与可解释性。
- 4.假设纳入模型的各特征变量之间不存在严重多重共线性，经过变量筛选与检验后，回归系数估计结果不会因共线性问题出现明显失真；同时，基于逻辑回归预测概率构建的低、中、高三级风险分层，以及基于 CART 决策树提取的阈值规则，具有统计显著性、稳健性和一定的临床实际意义。
- 5.假设连续特征的离散化方式科学合理，不会导致关键信息的大量丢失，Apriori 算法得到的支持度、置信度及提升度等指标能够较真实地反映痰湿体质高风险人群中特征组合的共现规律，而非由随机波动产生的虚假关联。
- 6.假设在干预优化模型中，患者在 6 个月周期内具有良好依从性，干预强度与训练频率保持固定不变，痰湿积分的变化主要由干预强度和频率决定，并满足稳定的递减规律；同时，年龄约束、活动能力约束和预算约束在整个干预周期内持续有效，从而保证优化模型所得方案具有可行性与实用性。

以下是本文所用到的符号。

符号	符号说明
n	样本总数
p	初始特征维度（指标数量）
y_i	第 i 个样本的高血脂症真实标签（0 为阴性，1 为阳性）
$\hat{y}_i$	模型对第 i 个样本的患病预测结果
P	样本患高血脂症的预测概率值
β_j	统计模型中第 j 个特征对应的回归系数
α	LASSO 回归中控制稀疏性的 L1 正则化惩罚系数
Gini	随机森林中衡量节点不纯度的基尼指数
VIF_j	第 j 个变量的方差膨胀因子，用于共线性检验
AUC	ROC 曲线下方的面积，用于评价风险预警模型的分类性能

Lift	关联规则挖掘中的提升度，衡量特征组合的相关强度
TC	总胆固醇（Total Cholesterol）
TG	甘油三酯（Triglyceride）
LDL - C	低密度脂蛋白胆固醇
HDL - C	高密度脂蛋白胆固醇
SUA	血尿酸（Serum Uric Acid）
FBG	空腹血糖（Fasting Blood Glucose）
BMI	身体质量指数（Body Mass Index）
S_{tcm}	痰湿体质积分
$S_{tcm}^{(0)}$	干预前的初始痰湿积分
$S_{tcm}^{(6)}$	干预 6 个月后的预测（期望）痰湿积分
OR	优势比（Odds Ratio），衡量体质对发病的贡献程度
I	运动干预强度决策变量（取值 1, 2, 3，代表低、中、高强度）
F	运动干预频率决策变量（单位：次/周）
C	6 个月干预方案的单位经济成本
C_{max}	患者可承受的经济成本上限（预算约束）
R_{age}	基于年龄段的运动强度硬约束阈值
R_{adl}	基于活动能力（ADL/IADL 评分）的身体耐受度约束
ΔS	痰湿积分的下降值（干预效果评价指标）
W	综合评分函数，用于识别核心特征组合的重要性

四、问题一模型的建立和求解

4.1 样本数据预处理与标准化

在模型构建之前，我们首先对原始数据进行系统性的预处理，以消除量纲差异、统一指标方向并提升模型收敛稳定性。考虑到医疗健康数据对可靠性与解释性的高要求，我们严格按照规范统计建模流程，对数据质量进行全面检验，并在此基础上实施标准化处理，从而保证后续建模结果的科学性与稳健性。

4.1.1 数据质量检验与可靠性分析

我们对附件所提供的 1000 例中老年样本开展全维度数据质量评估，包括缺失值检测、异常值识别、重复样本筛查以及变量分布特性分析。检验结果表明：数据集中不存在缺失值，整体完整性达到 100%；各连续变量未出现显著偏离分布范围的异常点，数据分布稳定；样本之间不存在重复或逻辑冲突情况；分类变量分布均衡，不存在类别极端失衡现象。

基于上述结果，我们认为该数据集具备较高的可靠性与代表性，无需进行插值填补或异常修正，可直接进入标准化与建模阶段，从而避免人为干预对数据结构的潜在扭曲。

4.1.2 极值化（Min-Max）归一化与正向化处理

鉴于各类生化指标在量纲与数值范围上存在显著差异，同时不同指标在健康意义上存在方向性差异，我们采用 Min-Max 归一化方法对数据进行无量纲化处理，并同步完成指标正向化转换。

我们将所有指标划分为两类：一类为“极大型指标”，即数值越大表示健康状态越优，如高密度脂蛋白（HDL-C）；另一类为“极小型指标”，即数值越大表示健康风险越高，如甘油三酯（TG）、低密度脂蛋白（LDL-C）及空腹血糖等。为统一指标解释方向，我们分别对两类指标采用对应的归一化变换，使其在数值层面满足统一的健康解释逻辑：

（1）对极大型（正向）指标，采用常规最小最大归一化：

$$X_{\text{new}} = \frac{X - X_{\min}}{X_{\max} - X_{\min}}$$

（2）对极小型（负向）指标，采用反向最小最大归一化：

$$X_{\text{new}} = \frac{X_{\max} - X}{X_{\max} - X_{\min}}$$

式中：X 为原始观测值， $X_{\min}$ 、 $X_{\max}$ 分别为该指标的全局最小值与最大值， X_{new} 为处理后落在 [0,1] 区间内的标准化值。通过上述处理，所有变量均被映射至[0,1]区间，同时保留原始数据的相对大小规律关系，为后续模型训练提供标准化输入。

4.1.3 变量处理规则

为保证数据结构的一致性与建模合理性，我们针对不同类型变量制定差异化处理策略：对于连续型变量（如血脂指标、血糖、血尿酸、BMI、痰湿积分及活动量表评分等），统一进行归一化与正向化处理；对于分类型变量（如性别、吸烟史、饮酒史及体质标签等），保持原有编码形式不变，以保留其类别信息；对于标签变量（高血脂诊断结果），仅作为模型预测目标，不参与任何形式的预处理。

通过上述规则，我们在保证数据信息完整性的前提下，实现了模型输入形式的统一化，为后续多模型融合奠定基础。

4.1.4 选择 Min-Max 归一化的合理性分析

相较于 Z-Score 标准化方法，我们最终选择 Min-Max 归一化，主要基于以下考虑：首先，原始数据不存在异常值，从根本上规避了 Min-Max 方法对极端值敏感的问题；其次，该方法能够完整保留变量之间的线性关系，更适用于 LASSO 等线性模型的参数估计；再次，归一化结果严格限定在[0,1]区间，有利于提升模型数值稳定性并满足多数机器学习算法的输入要求；此外，该方法能够与指标正向化处理协同完成，从而增强模型结果的可解释性。

因此，我们认为 Min-Max 归一化在本研究数据结构与建模需求下具有最优适配性。

如图 1 所示，该对比图直观展示了关键指标在 LASSO 回归与随机森林模型中的归一化重要性得分，可清晰识别同时对痰湿体质与高血脂风险具备解释力的核心指标。




图 1 关键指标的 LASSO 与随机森林归一化重要性对比

4.2 问题一第一小问的模型建立

针对“关键指标筛选”这一核心任务，我们从“体质表征能力”与“风险预警能力”两个维度出发，分别构建回归模型与分类模型，并通过多模型融合实现指标筛选的稳健性与解释性统一。

4.2.1 痰湿体质严重程度：LASSO 回归模型

由于痰湿体质积分为连续变量，我们将其视为回归问题进行建模。为解决医疗指标间普遍存在的多重共线性问题，并实现自动特征筛选，我们采用带 L1 正则化的 LASSO 回归模型。

该模型在最小化残差平方和的同时，通过引入 L1 惩罚项对回归系数进行收缩，使得部分不重要特征的系数压缩为零，从而实现变量筛选与模型简化的统一。我们认为，该方法能够在高维医疗数据中有效识别对痰湿体质具有关键表征作用的核心指标。

损失函数：

$$\text{Loss} = \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \alpha \sum_{j=1}^p |\beta_j|$$

前半部分为残差平方和，保证拟合精度；后半部分为 L1 正则项，强制不重要特征系数压缩至 0；最优特征为系数非 0 的指标。

4.2.2 高血脂发病风险：随机森林分类模型

针对高血脂发病风险这一二分类问题，我们构建随机森林分类模型。该模型基于集成学习思想，通过构建多棵决策树并进行投票融合，有效提升模型泛化能力并降低过拟合风险。

在特征重要性评估方面，我们采用基于基尼不纯度下降量（Mean Decrease in Impurity, MDI）的度量方法，对各特征在分类任务中的贡献进行量化。相较于传统线性模型，随机森林能够捕捉变量之间的非线性关系，并对共线性问题具有较强鲁棒性，因此特别适用于复杂医学数据的特征筛选。

特征重要性公式：

$$\text{Importance}(j) = \frac{1}{N_{\text{trees}}} \sum_{t=1}^{N_{\text{trees}}} \sum_{n \in \text{Nodes}(j)} \Delta \text{Gini}(n)$$

4.2.3 综合筛选规则

为同时兼顾“体质解释能力”与“风险预测能力”，我们进一步构建双模型融合的特征筛选机制。具体而言，我们首先分别提取 LASSO 回归模型中的回归系数绝对值 $|\beta_j|$ 以及随机森林模型中的特征重要性 RF_j指标，作为两种不同视角下的特征贡献度度量。

随后，我们对两类重要性指标分别进行归一化处理，以消除量纲差异，并在此基础上构建综合重要性评分函数。通过对两类指标赋予等权重，我们得到统一的特征评价标准，从而筛选出在两类任务中均具有较高贡献度的关键指标。

$$\text{LASSO}_j^* = \frac{|\beta_j| - \min(|\beta|)}{\max(|\beta|) - \min(|\beta|)}$$
$$\text{RF}_j^* = \frac{\text{RF}_j - \min(\text{RF})}{\max(\text{RF}) - \min(\text{RF})}$$

计算综合重要性得分将两个归一化结果等权重相加，得到综合重要性：

$$\text{Score}_j = \text{LASSO}_j^* + \text{RF}_j^*$$

（Score_j越高，说明该指标同时具备痰湿体质表征与高血脂预警双重价值。）

4.3 理论分析

从理论层面来看，LASSO 回归通过引入全局正则化约束，在高度相关的多维指标中实现稀疏表示，从而避免冗余变量对模型稳定性的干扰；随机森林则通过多树集成机制，有效降低模型方差，并能够捕捉复杂的非线性关系。

我们进一步指出，单一模型往往难以同时兼顾解释性与预测性能，而通过回归模型与分类模型的协同建模，可以分别从“体质刻画”与“疾病预警”两个角度对特征进行评价，从而实现多目标一致性筛选。因此，双模型融合策略在理论上具有更强的稳健性与解释优势。

4.4 实验结果

4.4.1 LASSO 回归结果

在 LASSO 回归模型中，我们采用交叉验证确定最优正则化参数 α ，以实现模型拟合精度与结构简洁性的平衡。其中， α 为 L_1 正则化惩罚系数，用于控制回归系数的压缩强度：当 α 较大时，惩罚作用更强，更多特征的回归系数会被压缩为 0，模型更加稀疏；当 α 较小时，惩罚作用减弱，更多变量被保留下来，模型复杂度相应提高。由于图 2 横轴采用 $-\log_{10}(\alpha)$ 表示，因此从左向右实际上对应 α 逐渐减小、惩罚力度逐步放松的过程。

由表 1 可知，不同准则下所筛选出的特征数量存在明显差异：最小 MSE 准则下 $\alpha = 0.005108$ ，仅保留 2 个核心变量，模型最为简洁，但可能存在对复杂信息刻画不足的问题；1-SE 准则与宽松准则分别保留 13 个与 17 个特征，在一定程度上增强了模型对痰湿体质的解释能力。结合图 2 可以进一步观察到，交叉验证误差随 α 变化呈现出“先下降、后趋于平稳或略有上升”的趋势，说明模型在惩罚过强时容易欠拟合，而惩罚过弱时又可能引入冗余变量，降低模型的简洁性与泛化能力。

表 1 LASSO 回归不同准则下特征选择结果

准则	alpha	选中特征数
最小 MSE 准则	alpha=0.005108	2
1-SE 准则	alpha=0.000957	13

结合图 2 可以进一步观察到，随着正则化参数 α 的增大，模型复杂度逐渐降低，特征数量不断减少，同时交叉验证误差呈现“先下降后上升”的典型趋势。最优 α 对应误差最低点，而 1-SE 准则则在保证误差基本不增加的前提下，选择更为稀疏的模型结构。我们认为，该图清晰揭示了模型在“拟合精度”与“结构简约性”之间的权衡关系。




图 2 LASSO 回归交叉验证 MSE 随 α 变化曲线

在变量筛选结果中，模型主要保留了活动能力指标（如 ADL 吃饭、ADL 洗澡、IADL 交通）以及血脂相关指标（TC、LDL-C 等），这一结果与原分析一致。同时，这些指标与最终筛选得到的 Top5 核心指标（TC、TG、LDL-C、HDL-C 及空腹血糖）具有良好的对应关系，说明血脂与代谢指标在体质刻画中具有重要作用。

从系数符号来看，活动能力变量整体呈负向影响，即生活自理能力越强，痰湿体质程度越低；而血脂指标（如 LDL-C）呈正向作用，表明代谢水平升高与痰湿体质加重具有一致趋势。这一结果与中医“脾主运化、活动有助于痰湿排出”的理论相一致。

需要指出的是，在最优参数下模型的决定系数 $R^2 = 0.0146$ ，整体拟合优度较低。这一结果表明，痰湿体质难以通过少量线性指标进行充分解释，其形成机制具有多因素耦合及潜在非线性特征。因此，该模型更适用于关键变量筛选，而非用于高精度预测。

综上，结合表 1 与图 2 分析可知，LASSO 回归能够在压缩变量的同时识别关键指标，并为后续 Top5 指标筛选提供重要依据。

4.4.2 随机森林分类结果

在随机森林模型中，我们采用 5 折交叉验证评估模型性能，结果显示 AUC 接近 1，分类准确率达到 0.996，表明模型具有极强的判别能力。

Top5 重要性排序：

表 2 随机森林模型特征重要性排序及累积占比（高血脂发病风险预警）

指标	重要性	累积
TG 甘油三酯	0.3375	0.3375
TC 总胆固醇	0.2911	0.6286
血尿酸	0.1563	0.7849
LDL-C	0.0672	0.8521
HDL-C	0.0494	0.9015

由表 2 可以清晰看出，甘油三酯（TG）与总胆固醇（TC）在特征重要性排序中占据前两位，且二者累计贡献已超过 60%。进一步结合图 3 的横向条形图可以直观发现，TG 的重要性显著高于其他变量，呈现明显“头部主导”结构，而血尿酸、LDL-C 及 HDL-C 则构成第二层次的重要指标。




图 3 高血脂风险预警指标特征重要性

图 4 展示了特征重要性的累积占比曲线，可以看到前 4 个特征已解释约 80%的信息，而前 12 个特征覆盖超过 95%的模型贡献。这一结果说明，高血脂风险的判别主要依赖少数关键指标，模型具有良好的降维特性与解释集中性。




图 4 随机森林特征重要性累积占比曲线

值得注意的是，活动能力相关指标在图 3 中几乎不占权重，这与 LASSO 模型形成对比。我们认为，这一现象反映出活动能力对高血脂的作用路径主要为间接影响，而非直接判别变量。

综合图 3、图 4 及表 2 可以得出结论：随机森林模型不仅具有极高的预测性能，同时其特征重要性分布与临床认知高度一致，验证了模型的可靠性与实际应用价值。

4.5 综合筛选结果

综合得分 Top5:

表 3 双模型综合筛选关键指标及意义

指标	综合重要性得分	说明
TC 总胆固醇	0.4550	综合得分最高，同时是痰湿体质与高血脂风险的核心指标

TG 甘油三酯	0.3889	高血脂预警能力最强,同时对痰湿体质有一定表征作用
ADL 吃饭	0.2401	主要表征痰湿体质,对高血脂的直接预警作用较弱
尿酸	0.1563	反映整体代谢水平,对高血脂风险有一定预测价值
LDL-C 低密度脂蛋白	0.1358	血脂核心指标,对痰湿体质与高血脂均有一定贡献

在综合筛选阶段，我们对 LASSO 回归与随机森林模型的特征重要性进行归一化处理，并构建统一评价指标。由表 3 可以看出，总胆固醇（TC）与甘油三酯（TG）在综合得分中排名前两位，表明其在体质表征与风险预警中均具有核心作用。

进一步结合表 4 可以发现，这些关键指标在两个模型中的表现具有一致性：例如 TC 在 LASSO 中表现为负向影响，在随机森林中重要性排名第 2；TG 在随机森林中排名第 1，同时在 LASSO 中也具有显著贡献。这种“双模型一致性”显著增强了特征筛选结果的可信度。

表 4 关键指标的双模型验证结果（LASSO + 随机森林）

指标	类型	LASSO 方向	RF 重要性排名
TC（总胆固醇）	血常规	负向	第 2
LDL-C（低密度脂蛋白）	血常规	正向	第 4
TG（甘油三酯）	血常规	正向	第 1
空腹血糖	血常规	正向	第 6
HDL-C（高密度脂蛋白）	血常规	正向	第 5

图 1 展示了各指标在 LASSO 与随机森林中的归一化重要性对比，可以直观观察到血脂指标在两个模型中均处于高位区域，而活动能力指标则主要集中在 LASSO 一侧。该图从可视化角度验证了“直接作用变量”与“间接作用变量”的差异。

通过对图 1、表 3 及表 4 的综合分析，我们可以进一步归纳出如下结构性结论：血脂与血糖指标构成连接中医体质与高血脂风险的核心中介变量，而活动能力则通过调节体质状态间接影响风险水平。

这一结论不仅在统计结果上得到验证，也与中医“体质调控—代谢变化—疾病发生”的理论路径高度一致，从而实现了中西医理论的统一表达。

4.6 问题一第二小问的模型建立

在完成关键指标筛选后，我们进一步分析不同中医体质对高血脂发病风险的影响。考虑到因变量为二分类变量（是否患高血脂），我们构建多元 Logistic 回归模型进行建模，其基本形式如下所示：

$$P(Y = 1|X) = \frac{1}{1 + e^{-(\beta_0 + \beta_1x_1 + \beta_2x_2 + \cdots + \beta_9x_9)}}$$

优势比（OR 值）：

$$OR_j = e^{\beta_j}$$

当 OR > 1 时，该体质为风险因素，积分越高发病风险越大；当 OR < 1 时，该体质为保护因素，积分越高发病风险越低；当 OR = 1 时，与发病风险无显著关联。建模前，我们先进行多重共线性检验（VIF），以保证回归系数估计稳定可靠。

4.7 理论分析

逻辑回归是处理二分类问题的经典方法，OR 值具有清晰医学解释力，适合用于风险贡献度分析。方差膨胀因子（VIF）用于检验自变量之间的线性相关程度，通常当 VIF > 10 时可认为存在严重多重共线性，可能导致系数失真、标准误膨胀。模型整体评价指标如伪 、AUC 与似然比检验则用于判断体质变量整体对高血脂的预测能力，而回归系数、OR 值、95% CI 与 P 值共同用于判断单一体质的作用方向、强度及统计显著性。

4.8 实验结果与分析

4.8.1 多重共线性检验（VIF）

方差膨胀因子计算公式：

$$VIF_j = \frac{1}{1 - R_j^2}$$

检验结果显示：九种体质的 VIF 均远小于 10，最大值仅为 1.2095，不存在严重多重共线性，满足多元逻辑回归建模条件。

表 5 九种中医体质多重共线性（VIF）检验结果

体质	VIF 值
平和质	1.209486
气虚质	1.037606
阳虚质	1.034495
阴虚质	1.028831
痰湿质	1.056834
湿热质	1.034797
血瘀质	1.041745
气郁质	1.033761
特禀质	1.023754

4.8.2 模型整体效果评价

模型拟合结果如下：McFadden 伪 $R^2 = 0.0042$ 较低，AUC=0.5479，接近随机水平 0.5，虽然比检验结果亦表明模型整体解释力有限。由此可见，九种体质无法单独有效预测高血脂发病风险。其原因在于，体质属于宏观中医分型，而高血脂受血脂、血糖、代谢状态与生活方式等微观因素直接驱动；体质对高血脂的影响更多表现为间接作用或中介传导，而非直接致病机制。




图 5 九种体质预测高血脂的 ROC 曲线

图 5 给出了仅使用九种体质预测高血脂风险的 ROC 曲线，AUC = 0.5479，进一步说明其判别能力较弱。

4.8.3 九种体质贡献度排序与结果分析

按回归系数绝对值对九种体质贡献度进行排序，尽管所有体质的 P 值均大于 0.05，未达到统计显著性，但其方向性趋势仍具一定参考价值。

表 6 九种体质对高血脂发病风险的贡献度

排名	体质	回归系数	OR 值	P 值	影响方向
1	气虚质	0.4497	1.568	0.1238	风险因素
2	平和质	0.3027	1.354	0.3400	风险因素

3	湿热质	-0.1892	0.828	0.5235	保护因素
4	血瘀质	-0.1835	0.832	0.5497	保护因素
5	阳虚质	0.0763	1.079	0.7956	风险因素
6	特禀质	-0.0567	0.945	0.8492	保护因素
7	气郁质	0.0479	1.049	0.8729	风险因素
8	痰湿质	-0.0261	0.974	0.9193	保护因素
9	阴虚质	0.0108	1.011	0.9709	风险因素




图 6 九种体质 Logistic 回归系数对比

如图 6 所示，横向条形图直观展示了九种体质逻辑回归系数的大小与方向；图 7 的森林图则进一步给出了各体质的 OR 值及 95%置信区间。




图 7 九种体质对高血脂发病风险的贡献度（森林图）

综合分析可得：气虚质贡献度最高（OR = 1.568），为最主要的潜在风险体质，符合“气虚运化无力、痰湿内停、血脂升高”的中医病机；平和质呈风险趋势，可能与样本中平和质人群健康管理松懈有关；湿热质与血瘀质则表现为保护趋势，提示其气血运行状态相对较为通畅；痰湿质系数接近 0，说明单纯体质分型不足以独立判断风险，必须结合血脂指标进行联合评估。整体而言，所有体质的 95% 置信区间均包含 1，说明在当前样本下，无任何一种体质具备独立显著的高血脂预测作用。

五、问题二模型的建立和求解

5.1 子问题一：多维度融合风险预警模型构建

5.1.1 模型构建思路

本子问题的目标在于融合中医体质、血常规指标、活动量表以及人口学信息四类特征，构建能够输出低风险、中风险与高风险三级结果的高血脂症风险预警模型，并进一步明确各风险等级的判别阈值及其临床解释依据。为实现这一目标，我们遵循“概率预测—风险分层—规则提取—分层验证”的整体建模思路。具体而言，我们首先以高血脂二分类标签为因变量，建立

逻辑回归概率预测模型，输出个体患病概率；随后结合 ROC 曲线的 Youden 指数与预测概率分布的分位数特征，构造低一中一高三级风险划分阈值；在此基础上，我们进一步训练 CART 决策树，从概率分层结果中反向提取具备可解释性的特征阈值规则；最后，通过比较不同风险等级中关键指标的均值变化趋势，对风险分层结果的合理性进行统计验证。通过这一流程，我们不仅能够实现较高精度的风险预测，还能够获得便于临床应用的显式规则，从而兼顾模型性能与医学可解释性。

5.1.2 逻辑回归概率预测模型

在风险预警模型的核心构建中，我们采用带 L2 正则化的逻辑回归模型，将高血脂症二分类问题转化为[0,1] 区间内的患病概率输出问题。其基本形式为：

$$P(Y = 1|X) = \frac{1}{1 + e^{-(\beta_0 + \sum_{i=1}^{32} \beta_i x_i)}}$$

其中，Y =1 表示样本患有高血脂症， X_j 表示第 j 个特征变量， β_j 为相应回归系数。为缓解类别不平衡对模型训练结果的影响，我们设置 `class_weight='balanced'`，并采用 5 折分层交叉验证对模型泛化能力进行评估。模型性能结果如表 7 所示。

表 7 高血脂症风险预警逻辑回归模型性能指标

指标	值
5 折 CV AUC	0.9719 ± 0.0089
5 折 CV ACC	0.9030 ± 0.0157
训练集 AUC	0.9030 ± 0.0157

从表 7 可以看出，我们构建的逻辑回归模型在 5 折交叉验证下取得了 AUC = 0.9719 的优异结果，说明模型对于高血脂症阳性与阴性样本具有极强的区分能力；同时，分类准确率达到 0.9030，表明模型在整体预测层面也具有较高稳定性。

进一步地，我们对模型输出的患病概率分布进行统计分析，结果显示：全体样本预测概率均值为 0.7268，标准差为 0.3773，最小值为 0.0000，最大值为 1.0000；确诊样本预测概率均值为 0.8871，标准差为 0.2168；健康样本预测概率均值为 0.1129，标准差为 0.1797。上述结果说明，模型对患病样本与健康样本给出的概率分布存在显著分离，为后续风险阈值设定提供了扎实依据。

如图 8 所示，该横坐标的数值源于逻辑回归模型对各个体样本输出的预测概率。该连续概率值直接映射了样本罹患高血脂症的风险系数：其值愈趋近于 1，表示模型判定该个体患病的置信度愈高；反之趋近于 0，则指示较低的患病风险。从预测概率分布直方图的形态特征来看，代表阴性（未确诊）人群的蓝色区域显著聚集于低概率区间，而代表阳性（确诊）人群的红色

区域则高度集中在趋近 1.0 的极高概率区间。这种显著的两极分化分布态势，充分印证了该模型具备优异的类别区分度与判别能力。基于此预测概率空间，研究进一步确立了 0.126 与 0.579 两个关键概率截断值（即图中黄、红虚线），作为量化评估的决策边界，以此将研究对象科学、有序地划分为低、中、高三级风险梯队。




图 8 逻辑回归模型预测概率分布直方图

为进一步分析不同特征对模型预测结果的影响，我们按照系数绝对值大小对逻辑回归模型中的变量进行排序，得到前 10 个关键特征，如表 8 所示。

表 8 逻辑回归模型特征系数前 10 排序（按绝对值）

排名	特征	类型	方向	系数
1	TG（甘油三酯）	血常规	正向 ↑	4.1189
2	TC（总胆固醇）	血常规	正向 ↑	2.9402
3	HDL-C（高密度脂蛋白）	血常规	负向 ↓	-0.7645
4	尿酸	血常规	正向 ↑	0.7169
5	LDL-C（低密度脂蛋白）	血常规	正向 ↑	0.6980

6	性别	人口学	负向 ↓	-0.3930
7	平和质	体质	正向 ↑	0.2642
8	气虚质	体质	正向 ↑	0.2238
9	痰湿质	体质	正向 ↑	0.1649
10	饮酒史	人口学	负向 ↓	-0.158

如图 9 所示，该条形图对各特征系数的大小与方向进行了可视化表达，能够帮助我们更加清晰地识别高血脂风险的主要驱动因素。




图 9 高血脂症风险预警逻辑回归模型的特征系数条形图

从结果上看，血常规指标在风险预警中占据主导地位，其中 TG、TC、HDL-C、血尿酸与 LDL-C 的系数绝对值位列前五，说明脂代谢与尿酸代谢异常构成高血脂风险识别的核心信息来源。尤其是 TG 的系数高达 4.1189，明显高于第二位的 TC，表明甘油三酯是本研究中最强的风险预警指标；HDL-C 的系数为负值，反映其对高血脂具有保护效应，这与临床医学对“好胆固醇”的认识保持一致。相比之下，体质变量虽然在模型中仍有一定贡献，但其系数显著低于血脂指标，说明中医体质在多维融合模型中的作用更多体现为辅助性风险修饰因素，而非主导性直接判别变量。这一结果进一步印证了我们在问题一中的结论，即高血脂的直接预警主要依赖代谢与生化特征，而体质特征更适合作为背景性、结构性信息参与联合建模。

5.1.3 三级风险阈值确定

在完成概率预测模型建立之后，我们需要进一步将连续型患病概率映射为具备实际意义的离散风险等级。为此，我们综合考虑 ROC 曲线最优判别点与样本概率分布特征，构建低风险、中风险和高风险三级分层阈值。

首先，基于 ROC 曲线计算 Youden 指数，得到最优二分类阈值为 0.5791，对应的 Youden 指数为 $J = 0.8630$ ，真阳性率 $TPR = 0.9016$ ，假阳性率 $FPR = 0.0386$ 。这一阈值可视为高风险与非高风险之间的最佳统计分界点。

其次，我们考察健康样本的概率分布情况，发现负例样本第 75 分位数 $Q_{75} = 0.1259$ ，即 75% 的健康个体其预测概率低于该值。因此，我们将其作为低风险上界，从而尽可能保证低风险组的纯净性。

综合两方面信息，我们最终确定：当预测概率低于 0.1259 时判定为低风险；当预测概率介于 0.1259 与 0.5791 之间时判定为中风险；当预测概率高于 0.5791 时判定为高风险。相应结果见表 9。

表 9 高血脂症三级风险阈值及依据

风险等级	概率阈值	选取依据
低风险	$P < 0.1259$	负例 Q_{75} ，确保 75%健康人归入低风险
中风险	$0.1259 \leq P \leq 0.5791$	介于健康分界与最优判别点之间
高风险	$P > 0.5791$	ROC Youden 最优点，确诊率最高

根据上述阈值划分，全体样本的风险等级分布及实际患病率见表 10

表 10 三级风险样本分布与实际患病率

风险等级	样本数 n	确诊人数	实际患病率
低风险	170	15	8.82%
中风险	108	64	59.26%
高风险	722	714	98.89%

由表 10 可知，高风险组中实际患病率高达 98.89%，几乎全部为确诊样本；中风险组患病率为 59.26%，表现出明显的过渡性质；低风险组患病率仅为 8.82%，说明绝大多数健康样本被正确归入低风险区域。由此可见，我们构建的三级风险阈值体系具有良好的区分效能，能够较为准确地实现由“健康—潜在风险—高度危险”的连续分层。

5.1.4 决策树提取特征分层阈值规则

虽然逻辑回归模型在概率预测方面具有较高精度，但其风险判定过程主要体现在系数加权

后的综合概率上，临床应用中不易直接转化为简洁直观的判别规则。为增强模型的可解释性，我们以三级风险分层结果为标签，构建 CART 决策树模型，参数设置为 $\text{max_depth}=4$ 、 $\text{min_samples_leaf}=20$ ，训练准确率达到 0.9010。

(1) 决策树结构（文本化）

```
|--- TG <= 1.92
|   |--- TC <= 6.16
|   |   |--- TG <= 1.41
|   |   |   |--- TC <= 5.38: 低风险
|   |   |   |--- TC > 5.38: 中风险
|   |   |--- TG > 1.41
|   |   |   |--- 尿酸 <= 383.50: 中风险
|   |   |   |--- 尿酸 > 383.50: 高风险
|   |   |--- TC > 6.16
|   |   |   |--- TG <= 0.87
|   |   |   |   |--- TC <= 7.00: 中风险
|   |   |   |   |--- TC > 7.00: 高风险
|   |   |   |--- TG > 0.87
|   |   |   |   |--- TC <= 6.36: 高风险
|   |   |   |   |--- TC > 6.36: 高风险
|   |--- TG > 1.92
|   |   |--- TC <= 3.66
|   |   |   |--- TG <= 2.36: 高风险
|   |   |   |--- TG > 2.36: 高风险
|   |   |--- TC > 3.66
|   |   |   |--- TG <= 2.01: 高风险
|   |   |   |--- TG > 2.01: 高风险
```

从决策树结构可以看出，TG 是首层分裂变量，说明其对风险分层的区分能力最强；TC 次之，构成第二层核心判别条件；当 TG 与 TC 处于边界区间时，尿酸进一步参与分层。这一结构与前述逻辑回归系数排序结果高度一致，说明不同模型在核心特征识别上具有良好一致性。

根据决策树可提取如下显式规则。

低风险规则唯一，即：

TG ≤ 1.92 且 TC ≤ 6.16 且 TG ≤ 1.41 且 TC ≤ 5.38, 置信度 93.10%

中风险规则共有三条:

TG ≤ 1.92 且 TC ≤ 6.16 且 TG ≤ 1.41 且 TC > 5.38, 置信度 60.71%

TG ≤ 1.92 且 TC ≤ 6.16 且 TG > 1.41 且 血尿酸 ≤ 383.50, 置信度 61.54%

TG ≤ 1.92 且 TC > 6.16 且 TG ≤ 0.87 且 TC ≤ 7.00, 置信度 48.28%

高风险规则包括:

TG ≤ 1.92 且 TC > 6.16 且 TG > 0.87 且 TC > 6.36, 置信度 97.96%

TG > 1.92 且 TC ≤ 3.66 且 TG > 2.36, 置信度 100.00%

TG > 1.92 且 TC > 3.66 且 TG ≤ 2.01, 置信度 95.00%

TG > 1.92 且 TC > 3.66 且 TG > 2.01, 置信度 100.00%

上述规则表明, 在高血脂风险分层中, TG、TC 与血尿酸构成最具解释力的阈值型指标体系。其中, TG 的阈值作用最为突出, 一旦其水平超过 1.92, 则样本几乎直接进入高风险区域; 而在 TG 较低的情况下, TC 与血尿酸则对中高风险的进一步区分起决定性作用。这一结果对于基层临床筛查具有较强现实意义, 因为其仅依赖少数常规检测指标, 易于推广实施。

5.1.5 关键特征在各风险等级均值对比

为进一步验证三级风险分层体系在数值层面的合理性, 我们比较了低风险、中风险与高风险组中关键指标的均值差异, 结果见表 11。

表 11 关键指标在低/中/高风险组的均值对比

特征	低风险	中风险	高风险
痰湿质	33.85	30.15	33.20
TC (总胆固醇)	4.06	5.18	6.45
TG (甘油三酯)	0.88	1.31	2.21
LDL-C	2.33	2.55	2.68
HDL-C	1.40	1.38	1.27
活动量表总分	49.51	48.92	49.87
BMI	21.84	21.88	21.96
空腹血糖	5.06	5.11	4.95




图 10 关键指标在不同高血脂风险等级中的分布对比

从表 11 可以看出，TC 与 TG 随风险等级的上升而显著增加，呈现出清晰的单调递增趋势；LDL-C 亦随风险等级小幅上升；HDL-C 则随着风险升高而下降，表现出典型的保护性指标特征。相比之下，活动量表总分、BMI 与空腹血糖在三组之间差异不明显，说明这些变量在本研究样本中虽然可能参与整体建模，但并非三级风险划分的主导驱动因素。痰湿质均值在高风险组与低风险组中相对接近，而中风险组略低，这也提示单一体质指标对风险分层的直接解释力有限，仍需与代谢指标结合分析。总体而言，关键血脂指标在不同风险等级之间呈现稳定梯度变化，进一步验证了我们所构建风险分层体系的统计有效性与医学合理性。

5.1.6 ROC 曲线与最优阈值

为从整体上评价风险预警模型的分类性能，我们绘制了 ROC 曲线，并计算其曲线下面积。结果显示，模型的 AUC 达到 0.9819，Youden 指数对应的最优阈值为 0.5791。

如图 12 所示，该 ROC 曲线整体贴近左上角，表明模型同时具有较高灵敏度与较高特异度。

AUC 高达 0.9819，说明我们构建的多维融合风险预警模型在区分高血脂阳性与阴性样本方面具有极强判别能力。与此同时，最优阈值 0.5791 与前文三级风险分层中的高风险下界保持一致，这表明我们的阈值设定并非经验性划分，而是建立在严格统计依据之上的结果。因此，从 ROC 曲线角度看，模型性能与风险分层方案之间形成了良好的闭环验证关系。




图 11 高血脂风险预警模型 ROC 曲线

5.1.7 子问题一结论

综上所述，我们构建的多维融合逻辑回归模型能够稳定输出高血脂患病概率，并在 5 折交叉验证下取得 $AUC = 0.9719$ 的优异表现，显示出较强的泛化能力与预测稳定性。基于 ROC 曲线 Youden 最优点与负例样本概率分位数，我们将个体风险划分为低风险、中风险和高风险三级，其中低风险阈值为 0.1259，高风险阈值为 0.5791；分层结果表明，高风险组实际患病率接近 99%，低风险组不足 9%，风险区分效果显著。进一步地，我们借助 CART 决策树从概率分层结果中提取出 TG、TC 与血尿酸三项核心阈值型规则，使模型不仅具备高精度，也具备较强临床可解释性。最后，通过关键指标在不同风险等级中的均值比较，我们验证了 TC、TG 与 HDL-C 等变量在风险分层中的梯度变化规律，从而说明该模型在统计意义与医学意义上均具有较高可靠性。由此可见，本子问题所建立的风险预警体系能够为中老年高血脂高危人群的早期识别与分级管理提供有效的量化支撑。

5.2 子问题二：痰湿体质高风险人群核心特征组合识别

5.2.1 研究思路

在完成高血脂症三级风险预警模型构建之后，我们进一步将研究对象聚焦于“痰湿体质且

处于高风险等级”的特定亚群，以识别其内部最具代表性的高危特征组合。相较于单变量显著性分析，特征组合识别更能够反映高风险人群中多因素共同出现的聚集规律，因此对于临床筛查、健康宣教与个体化干预均具有更直接的应用价值。基于这一考虑，我们采用“目标群体筛选—特征离散化—组间差异检验—共现模式分析—Apriori 频繁项集挖掘—核心组合排序—机制解释”的分析框架，对痰湿体质高风险人群进行组合特征挖掘。具体而言，我们首先从全样本中提取体质标签为痰湿质且风险等级为高风险的样本作为目标研究对象；随后，将连续型变量按照决策树阈值、临床标准与分位数标准离散化为适用于 Apriori 算法的二元项目；在此基础上，我们通过卡方检验比较痰湿体质高风险组与痰湿体质非高风险组之间的特征频率差异，识别具有显著区分力的单项因素；进一步地，结合特征共现热力图与 Apriori 频繁项集分析，提炼高风险组内部高频共现模式；最后，综合支持度、对比 Lift 及组合复杂度构建综合评分，对特征组合的重要性进行排序。通过这一流程，我们不仅能够识别“哪些因素重要”，还能够进一步回答“哪些因素倾向于共同出现并共同指向高风险”这一更具临床意义的问题。

5.2.2 目标群体筛选

按照前述风险分层结果，我们从全样本中筛选出所有痰湿体质个体，并进一步依据风险等级划分为高风险组与非高风险组。筛选结果显示，痰湿体质样本共 278 例，其中高风险 200 例，占比 71.90%；非高风险 78 例，占比 28.10%。具体结果如表 12 所示。

表 12 痰湿体质样本风险分布

分组	人数	占比
痰湿体质（总）	278	100%
痰湿体质 + 高风险	200	71.90%
痰湿体质 + 非高风险	78	28.10%

上述结果表明，在痰湿体质人群内部，高血脂高风险个体占比达到 71.9%，显著高于总体样本中的平均高风险比例。这说明痰湿体质与高血脂高风险之间存在较强关联，痰湿质不仅是一个体质标签，更可能构成高血脂风险聚集的重要背景条件。因此，将痰湿体质高风险人群作为进一步挖掘对象具有明确的统计意义与临床价值。

5.2.3 特征离散化处理

由于 Apriori 算法主要用于处理事务型或二元项目型数据，无法直接作用于连续变量，因此我们需要首先将与风险相关的连续型特征转化为离散化标签。在离散化过程中，我们综合考虑三类阈值来源：其一，直接采用前述决策树模型中得到的具有显著分层意义的阈值，如 TG、TC 与尿酸等关键指标；其二，采用临床常用判断标准，如活动量不足等行为特征；其三，针对

缺乏统一临床阈值的变量，采用样本的动态分位数或中位数作为切分依据，以增强离散结果对当前数据结构的适配性。通过这一策略，我们在保证临床可解释性的同时，也尽可能保留了变量对高风险的区分能力。离散化结果如表 13 所示。

表 13 特征离散化阈值与定义

特征	阈值	离散化标签	阈值来源
极高痰湿积分	≥ 62.25	痰湿积分 ≥ 62.25	动态 Q75
高 TG	> 1.92	甘油三酯偏高	决策树
高 TC	> 6.16	总胆固醇偏高	决策树
高尿酸	> 383.50	尿酸偏高	决策树
低活动量	< 40.00	活动量不足	临床标准
高 LDL-C	> 2.69	低密度脂蛋白偏高	动态中位数
低 HDL-C	< 1.31	高密度脂蛋白偏低	动态中位数
高 BMI	> 21.85	体重指数偏高	动态中位数
高血糖	> 4.99	血糖偏高	动态中位数
老年	≥ 3	年龄 ≥ 60 岁	固定分级

通过上述离散化处理，我们将原始多维连续特征统一映射为一组具备明确医学含义的二元特征标签，为后续卡方检验、共现分析及关联规则挖掘提供了标准化输入。

5.2.4 特征组间差异与卡方检验

在正式进行关联规则挖掘之前，我们首先对离散化后的候选特征进行组间差异检验，以识别哪些单项特征在痰湿体质高风险组与痰湿体质非高风险组之间具有显著的分布差异。具体方法上，我们对 15 项离散化特征逐一实施卡方检验，并结合频率差、卡方统计量、P 值与 Phi 系数综合评估其区分能力。结果显示，高 TG、高 TC 与高尿酸三项特征在两组之间差异极显著，高 LDL-C 亦达到显著水平，而其他特征未呈现统计学显著差异。具体结果如表 14 所示。

表 14 痰湿体质高/非高风险组特征差异与卡方检验

特征	高风险频率	非高风险频率	差异	卡方值	p 值	Phi 系数	显著性
高 TG (>1.92)	0.58	0.0385	0.5415	67.22	< 0.001	0.4917	***
高 TC (>6.16)	0.59	0.0769	0.5081	58.72	< 0.001	0.4596	***

高尿酸酸 (>383.50)	0.58	0.1923	0.3877	33.85	< 0.001	0.3489	***
高 LDL-C	0.50	0.2821	0.2179	10.82	0.001	0.1973	**
其余特征	—	—	—	—	> 0.05	—	ns

如图 12 所示，对比条形图进一步直观展示了痰湿体质高风险组与非高风险组在主要特征频率上的差异。




图 12 痰湿体质高 / 非高风险组特征频率对比图

从检验结果来看，高 TG 与高 TC 的频率差分别达到 0.5415 和 0.5081，是最具区分能力的两项变量；高尿酸虽然差异略低，但仍具有较强统计显著性与中等效应量；高 LDL-C 的差异与效应量相对较弱，但仍表明其在高风险识别中发挥一定辅助作用。这一结果说明，痰湿体质高风险人群与非高风险人群的差异主要体现在脂质代谢异常和嘌呤代谢异常层面，而非体重、活动量或血糖等一般性变量。换言之，在痰湿体质这一相同背景下，真正推动个体进入高风险状态的关键因素仍然是 TG、TC 与尿酸等核心代谢指标。

5.2.5 特征共现热力图分析

在单项特征差异分析的基础上，我们进一步考察痰湿体质高风险人群内部各离散特征之间的共现关系，以识别可能存在的聚集模式。为此，我们绘制特征共现热力图，并以两两特征在同一高风险样本中同时出现的频率作为共现强度度量。颜色越深，表示对应特征组合在高风险

组中的共同出现频率越高。

结果表明，高 TG 与高 TC、高血尿酸之间的共现频率最高，说明高血脂核心指标与尿酸代谢异常在痰湿体质高风险人群中具有显著聚集效应；此外，“饮酒”与“高 TG”、“低 ADL”之间也表现出较高共现频率，提示不良生活方式可能与代谢异常及功能状态下降共同作用于高风险形成；“老年”与“高 TC”的共现频率同样较高，反映年龄增长与胆固醇异常之间存在稳定关联。

如图 13 所示，特征共现热力图较为清晰地呈现了这些高频共现模式。




图 13 痰湿体质高风险人群特征共现热力图

我们认为，该结果具有两方面意义：其一，它验证了单变量卡方检验中所识别的核心代谢特征在群体层面的聚集性，并非孤立显著；其二，它为后续关联规则挖掘提供了结构性线索，即真正值得关注的高危模式并不是单一变量异常，而是若干具有共同病理基础的特征在同一个人群中的稳定共现。

5.2.6 Apriori 频繁项集挖掘

在完成特征离散化、组间差异检验与共现关系分析之后，我们进一步采用 Apriori 算法对痰

湿体质高风险人群中的高频特征组合进行系统挖掘，以识别具有代表性的风险共现模式。Apriori 算法是关联规则分析中的经典方法，其基本思想是利用频繁项集所满足的“向下封闭性”原则，逐层扩展候选项集，并通过支持度阈值筛除低频组合，从而有效识别在目标人群中稳定出现的特征集合。与单因素统计检验相比，Apriori 更强调特征之间的联合出现关系，因此能够揭示高风险个体内部更深层次的结构规律。

在规则评价方面，我们仍然保留并使用原有的三个核心指标，即支持度（Support）、置信度（Confidence）与 Lift 值。其定义如下。

1. 支持度（Support）：项集 X 在所有交易中出现的频率，反映特征组合的普遍性

$$\text{Support}(X) = \frac{\text{包含 X 的交易数}}{\text{总交易数}}$$

支持度越高，说明该组合在目标群体中越常见。

2. 置信度（Confidence）：包含 X 的交易中同时包含 Y 的条件概率，反映规则的可靠性

$$\text{Confidence}(X \rightarrow Y) = \frac{\text{Support}(X \cup Y)}{\text{Support}(X)}$$

其数值越大，表明当前件 X 出现时，后件 Y 同时出现的概率越高。

3. Lift 值：用于衡量 \$X\$ 和 \$Y\$ 之间的关联强度，是规则有效性的重要判别指标：

$$\text{Lift}(X \rightarrow Y) = \frac{\text{Confidence}(X \rightarrow Y)}{\text{Support}(Y)}$$

当 Lift > 1 时，说明 X 与 Y 呈正相关；当 Lift = 1 时，说明两者近似独立；当 Lift < 1 时，则说明两者呈负相关。

在具体实现中，我们设置最小支持度为 0.3、最小置信度为 0.5，在痰湿体质高风险组中挖掘频繁项集。经筛选，共得到 34 个频繁项集，其中长度大于等于 2 的 Top 高频特征组合如表 15 所示。

表 15 痰湿体质高风险人群长度≥2 的 Top 频繁项集

支持度	项集长度	频繁项集
0.360	2	老年 (≥60 岁)+ 高 TC (>6.16)
0.350	2	有饮酒 + 高 TG (>1.92)
0.340	2	男性 + 高血尿酸(>383.50)
0.335	2	有饮酒 + 高血尿酸(>383.50)
0.325	2	高 TG(>1.92) + 高血尿酸(>383.50)
0.320	2	高 TC(>6.16) + 高血尿酸(>383.50)
0.315	2	有饮酒 + 老年(≥60 岁)

从表 15 可以看出, 痰湿体质高风险人群中的频繁项集主要集中于“年龄—胆固醇异常”“饮酒—甘油三酯异常”“性别—血尿酸异常”等组合模式。其中, “老年(≥ 60 岁)+高 TC(>6.16)”具有最高支持度 0.360, 说明该组合在目标人群中最为常见; “有饮酒+高 TG(>1.92)”支持度为 0.350, 紧随其后, 表明饮酒行为与甘油三酯升高在痰湿体质高风险个体中具有显著的共现性。与此同时, “男性 + 高血尿酸”“有饮酒 + 高血尿酸”等组合也具有较高支持度, 提示在这一特定体质背景下, 代谢异常与生活方式因素之间存在较强耦合。

如图 14 所示, 该条形图清晰展示了痰湿体质高风险组 Top15 高频特征组合的支持度分布, 可直观用于筛选高频项集并比较不同组合的普遍性强弱。




图 14 痰湿体质高风险组高频特征组合 Top15 条形图

需要强调的是, 支持度较高仅说明某组合在高风险组内出现频繁, 但并不能直接说明其对高风险具有最强识别力。因此, 我们在后续分析中还需要结合关联规则分布及组间对比 Lift 值, 对这些高频组合的判别价值进行进一步筛选与排序。

5.2.7 关联规则分布与核心组合识别

在获得频繁项集之后, 我们进一步对关联规则挖掘结果进行了整理与分析, 以识别痰湿体质高风险人群中最具代表性的核心特征组合。在这一部分中, 我们不额外引入新的公式, 而是在保留原有评价指标体系的基础上, 结合支持度、置信度与 Lift 值的分布特征, 对不同规则的稳定性、普遍性与识别能力进行综合判断。

如图 15 所示，我们将关联规则的支持度、置信度与 Lift 值进行可视化展示，构建了关联规则分布散点图。通过该图我们可以看到，大多数规则主要集中在中高支持度与中高置信度区域，这说明本次挖掘得到的规则并非来源于个别样本中的偶然共现，而是在痰湿体质高风险组内部具有相对稳定的分布基础。与此同时，我们还注意到，多数规则对应的 Lift 值均大于 1，这表明这些特征组合之间并不是随机独立出现的，而是存在较为明确的正向关联关系。换言之，在痰湿体质高风险个体中，某些特征往往倾向于共同出现，并共同构成风险聚集模式。




图 15 痰湿体质高风险组关联规则分布散点图

进一步分析规则内容后，我们发现，高 Lift 的组合主要集中在代谢异常与人口学、生活方式特征的交叉配对上。例如，“有饮酒+高 TG”“男性+高尿酸”“老年+高 TC”等规则，不仅在高风险组中具有较高出现频率，而且表现出较强的共现关联性。这说明痰湿体质高风险状态并不是由单一生化异常孤立驱动的，而更可能是在体质偏颇背景下，由代谢异常与行为因素、年龄因素共同作用所形成的复合风险模式。

不过，仅依据高风险组内部的支持度或 Lift 值，还不足以说明某一组合对于“高风险”这一结果本身是否具有最强区分意义。换言之，有些组合虽然在高风险组中出现较多，但在非高

风险组中也可能同样常见，因此未必是最值得关注的核心识别模式。基于这一考虑，我们进一步比较了各特征组合在高风险组与非高风险组中的相对表现，并据此筛选出既具有较高出现频率、又能够较好区分两类人群的特征组合。

如图 16 所示，核心特征组合对比 Lift 排名图直观展示了不同组合的区分能力强弱。从排序结果来看，“有饮酒+高 TG (>1.92)” 的对比 Lift 明显高于其他组合，说明该模式在痰湿体质高风险组中呈现出显著富集，是最具特异性的高危组合。“老年 (≥60 岁) + 高 TC (>6.16)” 虽然对比 Lift 低于前者，但其支持度更高，意味着这一组合不仅具有较好的风险指示作用，而且在目标人群中更为常见，因而同样具有重要的筛查价值。




图 17 核心特征组合对比 Lift 排名图

综合考虑组合的普遍性、稳定性与区分能力后，我们最终识别出两组最具代表性的核心高危特征组合，结果如表 16 所示。

表 16 痰湿体质高风险核心特征组合排名

排名	特征组合	支持度	对比 Lift	综合得分
1	有饮酒+高 TG (> 1.92)	0.350	27.30	0.5898
2	老年 (≥60 岁) + 高 TC (> 6.16)	0.360	5.62	0.3557

从表 16 的结果来看，我们可以发现，“有饮酒+高 TG (>1.92)” 虽然在支持度上略低于“老年 (≥60 岁)+高 TC (>6.16)”，但其对比 Lift 高达 27.30，远高于其他组合，这表明该组合在高风险组中的相对富集程度非常突出，因此是最具识别价值的核心模式。相比之下，“老年+高 TC” 在总体出现频率上更高，说明这一组合是痰湿体质高风险人群中更为常见的一类典

型风险画像。换句话说，我们可以将前者理解为“特异性更强”的高危组合，而将后者理解为“覆盖面更广”的高危组合，这两者分别从不同角度刻画了痰湿体质高风险人群的典型特征结构。

总体而言，我们认为，这一部分分析进一步说明，痰湿体质高风险人群内部确实存在较为清晰的组合化风险模式，而且这些模式主要围绕“生活方式因素—脂代谢异常”和“年龄因素—胆固醇异常”两条主线展开。通过这样的分析，我们不仅能够识别出哪些单项指标与高风险关系密切，还能够进一步明确哪些因素更倾向于联合作用于高风险形成。相较于单变量分析，这种组合识别方式更有助于我们理解高风险状态的形成路径，也为后续机制解释和个体化干预策略制定提供了更具针对性的依据。

5.2.8 核心特征组合中西医机制解释

在识别出核心高危特征组合后，我们进一步对其可能的形成机制进行分析，以增强关联规则结果的解释性。总体来看，这些组合不仅在统计上具有较强的识别能力，也在一定程度上反映了痰湿体质高风险状态形成的内在路径。

对于“有饮酒+高 TG (>1.92)”这一组合，我们认为其主要体现了生活方式因素与脂代谢异常之间的协同作用。饮酒可在一定程度上影响脂质代谢，促进甘油三酯升高，而痰湿体质人群本身就具有痰湿内聚、代谢失衡的倾向，因此在饮酒因素作用下，更容易出现脂质异常并形成高风险状态。从中医角度看，饮酒易助湿生痰，与痰湿体质“湿聚痰生”的病机特点较为一致。

对于“老年 (≥ 60 岁)+高 TC (>6.16)”这一组合，我们认为其主要反映了年龄增长背景下胆固醇异常的累积效应。随着年龄增加，机体代谢功能逐渐减弱，总胆固醇更易升高；而对于痰湿体质者而言，这种变化可能进一步加重湿浊内停和膏脂积聚，从而使该组合在高风险组中表现出较强代表性。

综合来看，我们识别出的两组核心特征组合分别对应了生活方式驱动和年龄累积两类风险路径。这说明痰湿体质高风险状态并非由单一因素决定，而更可能是在体质偏颇基础上，多种因素共同作用的结果，也为我们后续开展有针对性的健康干预提供了依据。

5.2.9 子任务二结论

通过对子任务二的分析，我们进一步刻画了痰湿体质高风险人群的特征结构，并在差异分析、共现分析和关联规则挖掘的基础上，识别出了具有代表性的核心高危组合。

我们发现，痰湿体质人群中的高风险者往往同时伴随血脂异常以及年龄、饮酒等因素特征，说明其风险形成并不是单一指标异常的结果，而是多种因素共同聚集的表现。在关联规则结果中，多数规则具有较好的支持度、置信度和 Lift 水平，也进一步提示高风险组内部存在相对稳

定的特征共现模式。

在此基础上，我们最终筛选出“有饮酒+高 TG(>1.92)”和“老年(≥60 岁)+高 TC(>6.16)”两组核心特征组合。前者在高风险组中的富集程度更高，具有较强的区分能力；后者则具有更高的支持度，在目标人群中更为常见。我们认为，这两类组合分别代表了痰湿体质高风险人群中较为典型的两种风险模式。

总体而言，本部分分析不仅进一步验证了痰湿体质与高血脂高风险之间的密切联系，也说明从“特征组合”而非“单一指标”的角度进行识别，更有助于我们理解高风险状态的形成特点，并为后续的精准确筛与分类干预提供参考。

六、问题三模型的建立和求解

6.1 模型构建

问题三的本质在于构建一个兼顾疗效与成本的约束优化模型，使痰湿体质患者在年龄、活动能力和预算限制条件下获得 6 个月期内的最优干预路径。为此，我们围绕“积分动态递推—中医调理分级—成本累积计算—约束筛选—最优方案确定”的逻辑主线建立模型，并将个体化干预问题形式化为离散决策优化问题。

6.1.1 中医调理分级规则

考虑到痰湿积分能够较好反映患者当前痰湿偏颇程度及相应调理需求，我们依据积分区间对中医调理等级进行划分。

$$L_m = \begin{cases} 1 \text{ (基础调理)}, S_{m-1} < 59 \\ 2 \text{ (中度调理)}, 59 \leq S_{m-1} \leq 61 \\ 3 \text{ (强化调理)}, S_{m-1} \geq 62 \end{cases}$$

对应月成本：

$$C_{TCM}(1) = 30, C_{TCM}(2) = 80, C_{TCM}(3) = 130$$

6.1.2 月度积分下降率模型

为描述运动干预对痰湿积分改善的作用过程，我们建立月度积分下降率模型，用于刻画不同强度与频率组合下单位时间内的干预效果。该模型假定痰湿积分的下降主要由活动干预强度与训练频率共同决定，并以固定比例衰减的形式反映积分改善过程。该设定能够在保持模型简洁性的同时，较为直观地体现“更高强度或更高频率通常带来更大改善幅度”的干预规律。

$$r = \begin{cases} 0, f < 5 \\ 0.03I + 0.01(f - 5), f \geq 5 \end{cases}$$

6.1.3 痰湿积分递推公式

每月积分更新：

$$S_m = S_{m-1} \times (1 - r), \quad m = 1, 2, \dots, 6$$

6 个月最终积分：

$$S_6 = S_0 \times (1 - r)^6$$

在上述递推关系下，我们能够对任意给定干预方案在 6 个月内的积分变化过程进行完整模拟。与静态评估不同，该递推机制能够体现前一阶段干预结果对后一阶段状态的累积影响，因此更适合用于描述连续健康管理场景中的体质改善路径。

6.1.4 成本模型

月成本：

$$C_m = C_{TCM}(L_m) + 4f \times C_{act}(I)$$

6 个月总成本：

$$C_{total} = \sum_{m=1}^6 C_m$$

单次活动成本：

$$C_{act}(1) = 3, C_{act}(2) = 5, C_{act}(3) = 8$$

成本模型用于量化不同干预方案在整个周期内的经济投入。我们将中医调理等级成本与运动干预成本纳入统一框架进行核算，从而使模型既关注疗效改善，也同步考虑患者的经济可承受性。该处理方式有助于避免单纯追求积分下降而忽视实际支付能力的问题，使优化结果更贴近真实应用情境。

6.1.5 约束条件

1. 年龄约束

40–59 岁：可选用 1、2、3 级强度

60–79 岁：可选用 1、2 级强度

80–89 岁：仅可选用 1 级强度

2. 活动量表总分约束

<40 分：仅 1 级强度

40 ≤ 总分 < 60 分：可选用 1、2 级强度

≥ 60 分：可选用 1、2、3 级强度

3. 预算约束：

$$C_{total} \leq 2000$$

4. 取值约束：

$$I \in \{1,2,3\}, f \in \{1,2,\dots,10\}$$

上述约束条件分别从生理耐受、安全边界与经济可行性三个层面对优化空间进行限定。其中，年龄约束主要反映不同年龄阶段患者在运动强度承受能力上的客观差异；活动量表总分约束则进一步体现个体功能状态对干预等级选择的限制；预算约束保证最终方案具备现实可执行性。三类约束共同构成个体化干预方案的可行域。

6.1.6 目标函数

$$\min_{I,f} S_6 = S_0 \times (1 - r)^6$$

满足全部约束条件。

在目标设定上，我们综合考虑“最大化干预收益”与“最小化经济成本”两方面要求，将其统一纳入优化框架。其本质是在所有满足安全性与预算限制的候选方案中，选择能够实现更优积分改善效果的方案；当多组方案效果接近时，再优先考虑成本更低的方案。由此，模型所得结果能够兼顾疗效、经济性与实施性。

6.2 模型求解方法

由于本题的决策空间规模较小，强度变量最多仅有 3 种取值，频率变量最多为 10 种取值，因此全部候选组合总数不超过 30 种。在此情形下，采用穷举法求解不仅计算代价极低，而且能够保证获得全局最优解，避免启发式算法可能带来的局部最优风险。具体流程如下：

- 1.根据患者的年龄组和活动量表总分，计算允许强度集合；
- 2.遍历所有（强度，频率）组合；
- 3.对每个组合模拟 6 个月积分变化与成本累积；
- 4.筛选总成本≤2000 元的可行方案；
- 5.在可行方案中选择最终积分最低的方案。

相较于复杂优化算法，穷举法在本研究场景下更具适配性。一方面，其结果透明、计算过程可追溯，便于医学解释与实际应用；另一方面，在样本量较大但单个个体决策空间较小的情况下，该方法能够稳定输出精确最优解，因此具有较强的实用价值。

6.3 典型样本最优干预方案（ID=1、2、3）

为直观展示模型的求解效果与个体化决策特征，我们选取 3 个具有代表性的痰湿体质样本进行分析。通过比较不同年龄、活动能力和初始积分条件下的最优方案差异，可以更清晰地说明模型如何在约束条件下实现差异化匹配。

6.3.1 样本 ID=1

患者特征

初始痰湿积分：64.0

年龄组：50-59 岁

活动量表总分：38.0

允许强度：仅 1 级

最优方案：强度 1 级+频率 10 次/周

表 17 样本 ID=1 六个月干预详情

月份	月初积分	TCM 分 级	强度	频率	下降率	月末积分	月成本 (元)
1	64	3	1	10	8%	58.88	250
2	58.88	1	1	10	8%	54.17	150
3	54.17	1	1	10	8%	49.84	150
4	49.84	1	1	10	8%	45.85	150
5	45.85	1	1	10	8%	42.18	150
6	42.18	1	1	10	8%	38.81	150

解读：样本 1 的活动量表总分低于 40 因此在安全约束下仅允许采用 1 级强度。尽管强度水平受限，但通过将训练频率提高至 10 次/周，仍可在预算范围内获得较为显著的积分改善效果。该结果表明，对于功能状态较弱的患者，提高频率是弥补强度限制的有效方式，同时低强度方案的经济负担相对较轻，具备较高性价比。

6.3.2 样本 ID=2

患者特征

初始痰湿积分：58.0

年龄组：40-49 岁

活动量表总分：40.0

允许强度：1、2 级

最优方案：强度 2 级+频率 10 次/周

表 18 样本 ID=2 六个月干预详情

月份	月初积分	TCM 分级	强度	频率	下降率	月末积分	月成本 (元)
1	58	1	2	10	11%	51.62	230
2	51.62	1	2	10	11%	45.94	230

3	45.94	1	2	10	11%	40.89	230
4	40.89	1	2	10	11%	36.39	230
5	36.39	1	2	10	11%	32.39	230
6	32.39	1	2	10	11%	28.82	230

解读：样本 2 在年龄与活动能力方面均允许采用更高一级的运动强度，因此模型优先选择 2 级强度并配合最高频率。与样本 1 相比，该方案在成本上有所增加，但积分下降幅度显著扩大，表明当患者具备更强身体耐受能力时，提升干预强度能够获得更高的边际收益。该结果也说明，在预算约束并不构成瓶颈的条件下，强度升级通常优于单纯维持低强度方案。

6.3.3 样本 ID=3

患者特征

初始痰湿积分：59.0

年龄组：40-49 岁

活动量表总分：63.0

允许强度：1、2、3 级

最优方案：强度 3 级+频率 9 次/周

表 19 样本 ID=3 六个月干预详情

月份	月初积分	TCM 分级	强度	频率	下降率	月末积分	月成本 (元)
1	59	2	3	9	13%	51.33	368
2	51.33	1	3	9	13%	44.66	318
3	44.66	1	3	9	13%	38.85	318
4	38.85	1	3	9	13%	33.8	318
5	33.8	1	3	9	13%	29.41	318
6	29.41	1	3	9	13%	25.58	318

解读：样本 3 年龄较轻、活动能力较强，因此可进入最高强度可行域。模型最终选择“3 级强度+9 次/周”而非“3 级强度+10 次/周”，其根本原因在于后者将突破预算上限。由此可见，对于高耐受能力患者，模型遵循“优先保证强度、再依据预算调节频率”的决策逻辑，从而在成本约束下实现干预收益最大化。

6.4 患者特征 — 最优方案匹配规律

在完成典型样本分析后，我们进一步对全部 278 名痰湿体质患者的最优方案进行归纳总结，以提炼具有普适性的匹配规律。按照患者可承受的最大强度水平，可将其划分为以下三组：

A 组（仅允许 1 级强度）：92 人

统一方案：强度 1+频率 10 次/周

B 组（允许 1-2 级强度）：171 人

统一方案：强度 2+ 频率 10 次/周

C 组（允许 1-3 级强度）：15 人

方案：强度 3+频率 9 次/周（部分 TCM3 级为 8 次/周）

整体最优强度分布：1 级 92 人、2 级 171 人、3 级 15 人

整体最优频率分布：8 次/周 5 人、9 次/周 10 人、10 次/周 263 人

上述分布结果表明，不同患者虽然在初始积分、年龄及活动能力方面存在差异，但最优方案在结构上呈现出较强规律性，说明模型具备较好的稳定性与归纳价值。进一步地，我们可将其概括为以下几条核心规律：

1，强度策略——就高不就低

在满足年龄约束与活动能力约束的前提下，最优方案几乎总是优先选择允许范围内的最高强度。其原因在于，强度每提升一级所带来的积分下降率增益，通常明显高于频率增加一次所带来的改善幅度。因此，从优化结果看，强度变量是决定干预效果的主导因素，具有优先配置价值。

2.频率策略——预算允许内拉满

在强度确定后，频率通常被配置至预算允许范围内的最大水平。统计结果显示，绝大多数患者的最优频率均达到 10 次/周上限，说明在当前成本参数设定下，预算约束对多数个体并非最紧约束条件。只有少数初始调理等级较高、前期成本占用较大的患者，才需要适度下调频率以维持整体方案可行。

3.TCM 分级的首月效应

患者初始 TCM 分级越高，第 1 个月所需承担的调理成本越高，从而压缩后续频率配置空间。这意味着高积分患者在干预初期面临更强的资金压力。然而，随着痰湿积分逐月下降，调理等级可能下调，月度成本也随之下降，进而释放更多预算空间。因此，优化结果呈现出较为明显的“前期投入较高、后期成本回落”的阶段特征。

4.经济效率递减规律

从 A 组到 C 组，患者可承受强度逐步提高，最优方案对应的总成本亦明显上升，但积分改善的边际收益并未同步线性增长。这表明更高强度方案虽然在绝对疗效上更优，但其单位成本

带来的额外改善存在一定递减趋势。对于预算有限或耐受能力受限的患者而言，低强度配合高频次方案仍然具有较高的投入产出比。

6.5 模型结论

综合上述建模与求解结果可以看出，我们所构建的约束优化模型能够在年龄、活动能力及预算等多重现实约束下，为痰湿体质患者生成 6 个月周期内的个体化最优干预方案。由于决策变量仅包括有限个离散强度与频率组合，采用穷举法不仅计算效率高，而且能够保证所得结果为全局最优解，因此模型在方法上具有较强的可靠性与可操作性。对典型样本的分析表明，模型可根据患者初始痰湿积分、身体耐受水平及经济承受能力的差异，形成具有针对性的干预路径，其中样本 1、样本 2、样本 3 的痰湿积分分别下降 39.4%、50.3%和 56.6%，均在预算约束范围内实现了较为显著的改善效果。

进一步从全体痰湿体质患者的最优方案分布来看，模型呈现出较为稳定的决策规律：在满足安全约束的前提下，最优方案通常优先选择允许范围内的最高干预强度，并在预算允许范围内尽可能提高训练频率，最终形成“强度优先、频率适配”的总体策略。这说明，与单纯增加频率相比，提升强度对痰湿积分下降具有更显著的边际贡献，而频率的作用更多体现在对既定强度方案的补充优化。总体而言，本模型不仅能够实现痰湿体质干预方案的定量化与个体化设计，还能够提炼出具有推广意义的患者特征—方案匹配规律，从而为中老年痰湿体质人群的分级管理与精准干预提供较为清晰的决策依据。

七、模型的优缺点分析

（1）模型优点

1.多维度融合，预警精度高

融合中医体质、血常规、活动量表、人口学四大维度特征构建逻辑回归预警模型，5 折交叉验证 AUC 达 0.9719，高风险组实际患病率 98.89%，低风险组仅 8.82%，分层效果优异，可精准识别高血脂高危人群。

2.可解释性强，贴合临床应用

采用浅层决策树提取显式风险判定规则，核心指标仅 TG、TC 血尿酸 3 项，规则简洁直观，无需复杂计算即可直接用于基层临床筛查，符合中医与西医结合的诊疗逻辑。

3.优化模型实用，干预方案个性化

针对痰湿体质构建约束优化干预模型，以最小化痰湿积分、控制经济成本为目标，结合年龄、活动能力设置约束，输出 6 个月固定干预方案，患者依从性高，且形成通用的“患者特征-最优方案”匹配规律。

4.算法稳健，适配医疗数据特性

数据无缺失、无异常值，采用 Min-Max 归一化统一量纲；LASSO 回归解决特征共线性问题，随机森林精准筛选关键指标，Apriori 算法有效挖掘特征组合，各类算法适配医疗数据小样本、高维度、强解释性需求。

5.中西医结合，理论与实践统一

模型构建兼顾西医血脂代谢指标与中医痰湿体质病机，核心特征组合与干预策略均符合中西医病理机制，既满足现代医学量化标准，又贴合中医调理原则，研究成果具备落地价值。

（2）模型缺点

1.体质独立解释力有限

九种体质单独预测高血脂的 AUC 仅 0.5479，所有体质 OR 值均无统计显著性，单纯依靠体质分型无法有效预警发病，需结合血脂指标才能实现精准评估。

2.决策树特征覆盖范围窄

风险分层决策树仅选用 TG、TC、血尿酸 3 项指标，未纳入痰湿积分、活动量表等中医与行为特征，弱化了体质与生活方式对风险的影响，规则全面性不足。

3.干预模型为静态固定方案

假设 6 个月干预强度与频率固定，未考虑患者痰湿积分下降后身体耐受度提升、依从性变化等动态因素，缺乏自适应调整机制，与实际干预场景存在偏差。

4.样本代表性存在局限

研究样本仅针对特定中老年人群，未覆盖青年、老年高龄等全年龄段，且未纳入地域、饮食习惯、基础疾病等混杂因素，模型泛化能力受样本范围限制。

5.关联规则提升度偏低

痰湿体质高风险组内关联规则 Lift 值仅 1.0~1.14，特征间协同效应较弱，核心组合区分力依赖组间对比 Lift，内部关联挖掘深度不足。

（3）改进方向

- 1.引入动态干预模型，根据患者每月痰湿积分、活动能力变化实时调整干预强度与频率。
- 2.融合深度学习与可解释 AI，在保证精度的同时，纳入更多体质、行为特征完善风险规则。
- 3.扩大样本范围，增加地域、年龄、生活习惯等维度数据，提升模型泛化性与普适性。
- 4.结合时间序列分析，长期追踪患者指标变化，优化风险预警与干预效果评估体系。

参考文献

- [1] 木尼热·木塔力甫, 李晓梅. 血脂异常流行现状及相关危险因素[J]. 临床医学进展, 2023, 13(11): 17090-17098.
- [2] 中国心血管健康与疾病报告编写组. 中国心血管健康与疾病报告 2022 概要[J]. 中国循环杂志, 2023, 38(06): 583-612.
- [3] 安冬青, 吴宗贵, 梁春, 等. 血脂异常中西医结合诊疗专家共识[J]. 中国全科医学, 2017, 20(3): 262-269.
- [4] 戴宇充, 李卓娴, 黄国东, 等. 中西医结合治疗高脂血症的研究进展[J]. 亚太传统医药, 2024, 20(01): 215-219.
- [5] 程卓卓, 张睿, 胡娇, 等. 老年人慢性病共病与日常生活活动能力受损的关联研究[J]. 中国全科医学, 2026, 29(02): 219-225.
- [6] 中国血脂管理指南修订联合专家委员会. 中国血脂管理指南(2023 年)[J]. 中华心血管病杂志, 2023, 51(03): 221-255.